

Da 191 a 25 covariate: un modello lineare parsimonioso e interpretabile per l'Italian Fragility Composite Index

Progetto di Statistica Applicata — Report di estensione

Sommario

Questo report documenta un'iterazione del benchmark lineare per l'IFC realizzata in risposta al feedback del docente. Il primo benchmark, con 191 covariate selezionate da LASSO, raggiungeva un R^2 out-of-sample di 0,825, ma era troppo denso per essere discusso in modo sostantivo. Abbiamo quindi derivato un modello parsimonioso in tre passi espliciti: eliminazione iterativa della multicollinearità tramite Variance Inflation Factor, selezione delle top-N covariate per effetto standardizzato, e un filtro di significatività che sostituisce qualsiasi coefficiente non significativo con il candidato successivo del ranking. Su richiesta esplicita del docente, l'estensione del comune (superficie totale) è stata esclusa a monte, perché è un descrittore statico e non un driver di fragilità una volta che tutto il resto del modello è espresso in densità pro-capite. Il modello finale ha 25 covariate, tutte significative a $p < 10^{-6}$, con VIF massimo di 6,4. Il suo R^2 out-of-sample è 0,784: una perdita controllata di 0,041 rispetto al benchmark a 191 covariate. L'estensione con linear mixed model con random intercept annidato regione/provincia recupera quasi tutta la perdita, raggiungendo $R^2 = 0,818$, solo 0,007 sotto il benchmark originale. Il test di Moran sui residui rileva ancora una autocorrelazione spaziale positiva significativa ($I = 0,234$, $p < 0,001$), confermando che la struttura spaziale è intrinseca alla fragilità comunale italiana e non un artefatto del set di covariate. Diagnostiche aggiuntive su calibrazione, incertezza predittiva e normalità dei residui completano la valutazione e sono discusse in sezioni dedicate.

Perché questa estensione era necessaria

Dopo la presentazione del primo benchmark il docente ha sollevato quattro punti:

- **troppe covariate:** 191 è illeggibile in un poster o in una singola slide; il range gestibile per un pubblico è 10–20;
- **multicollinearità:** il primo report aveva solo una nota qualitativa su $PM_{10}/PM_{2,5}$; un'analisi VIF sistematica avrebbe detto quante delle 191 sono predittori realmente indipendenti;
- **ridge vs lasso:** un confronto Elastic Net su diversi parametri di mix avrebbe chiarito se la scelta del regolarizzatore guida il risultato;
- **superficie:** la variabile `Superficie_totale_Kmq` è una caratteristica statica del comune e non dovrebbe apparire in un modello di fragilità dove ogni altro conteggio è già stato normalizzato a densità pro-capite.

Questa estensione risponde a tutti e quattro. Il confronto numerico con il run originale a 191 covariate è esplicito in tutto il documento.

1 Specificazione dei modelli

Usiamo quattro varianti di modello annidate. Nell'intero documento i indica l'osservazione comune $\times$ anno e j la covariata. I predittori X_{ji} sono standardizzati, quindi $\hat{\beta}_j$ è la variazione attesa di IFC associata a un aumento di una deviazione standard della covariata j .

Linear model parsimonioso (LM). Baseline con 25 covariate fisse:

$$\text{IFC}_i = \beta_0 + \sum_{j=1}^{25} \beta_j X_{ji} + \varepsilon_i, \quad \varepsilon_i \sim \mathcal{N}(0, \sigma^2). \quad (1)$$

Random intercept di regione (M_{geo}). Aggiunge un livello base per regione:

$$\text{IFC}_i = \beta_0 + \sum_{j=1}^{25} \beta_j X_{ji} + u_{r(i)} + \varepsilon_i, \quad u_r \sim \mathcal{N}(0, \sigma_R^2), \quad (2)$$

dove $r(i) \in \{1, \dots, 20\}$ è la regione del comune i . Il termine $u_{r(i)}$ è la fragilità residua media della regione r che i fixed effects non riescono a spiegare.

Random intercept regione/provincia annidato ($M_{\text{geo,nested}}$). Aggiunge un secondo livello a livello provinciale:

$$\text{IFC}_i = \beta_0 + \sum_{j=1}^{25} \beta_j X_{ji} + u_{r(i)} + v_{p(i)|r(i)} + \varepsilon_i, \quad v_{p|r} \sim \mathcal{N}(0, \sigma_P^2), \quad (3)$$

con $p(i)$ una delle 107 province. Ogni provincia ha la propria fragilità residua sopra quella regionale.

Random intercept di macroclasse GRINS (M_{tax}). Sostituisce la gerarchia geografica con la tassonomia GRINS:

$$\text{IFC}_i = \beta_0 + \sum_{j=1}^{25} \beta_j X_{ji} + t_{m(i)} + \varepsilon_i, \quad t_m \sim \mathcal{N}(0, \sigma_T^2), \quad (4)$$

dove $m(i) \in \{\text{Italia interna}, \text{Italia di mezzo}, \text{Italia metropolitana}\}$ è la macroclasse GRINS.

Regione + macroclasse incrociati ($M_{\text{geo+tax}}$). Combina regione e macroclasse come due random intercepts incrociati. Verifica se la tassonomia aggiunge qualcosa oltre alla geografia quando entrambe sono nel modello:

$$\text{IFC}_i = \beta_0 + \sum_{j=1}^{25} \beta_j X_{ji} + u_{r(i)} + t_{m(i)} + \varepsilon_i. \quad (5)$$

2 Metodo

2.1 Pruning via Variance Inflation Factor

Per un modello lineare con p predittori,

$$\text{VIF}_j = \frac{1}{1 - R_j^2}, \quad R_j^2 = R^2(X_j \sim X_{-j}), \quad (6)$$

è la quota di varianza di X_j già spiegata dagli altri predittori. $\text{VIF} = 1$ corrisponde a indipendenza perfetta; $\text{VIF} > 10$ è la soglia convenzionale di seria collinearità.

Partendo dalle 191 covariate selezionate da LASSO (esclusa a monte la superficie), eliminiamo iterativamente la covariata con il VIF massimo e rifittiamo. La procedura si ferma dopo 34 iterazioni quando il VIF massimo scende sotto 10. I peggiori hanno VIF oltre cento (es. `mef_tot_classi_amm`, $\text{VIF} = 159$). Il log completo è in `outputs/parsimonious_model/vif_drop_log.csv`.

2.2 Ranking e selezione per effetto standardizzato

Sulle 157 covariate VIF-pulite fittiamo un modello lineare con predittori standardizzati e le ordiniamo per $|\hat{\beta}_j|$. La standardizzazione rende i coefficienti direttamente confrontabili tra variabili eterogenee. Le prime $n = 25$ formano il set candidato.

2.3 Filtro di significatività

Quando rifittiamo le top-25 per $|\hat{\beta}|$, occasionalmente una non risulta significativa: il suo $|\hat{\beta}|$ era guidato da una residua collinearità che la soglia VIF di 10 non aveva eliminato del tutto. Lo script rimuove automaticamente i coefficienti con $p > 0,05$ e li sostituisce con il candidato successivo del ranking, poi rifitta e ripete finché o tutte le 25 sono significative o il pool di candidati è esaurito. Nel nostro run è bastata una sostituzione.

2.4 Estensione mixed-model e diagnostica spaziale

Rifittiamo le quattro varianti mixed-model della Sezione 1 sul nuovo set di 25 covariate, e ricalcoliamo il Moran's I sui residui di $M_{\text{geo,nested}}$. I pesi spaziali sono il grafo simmetrico ai 5 vicini più prossimi usato in precedenza.

2.5 Cross-check Elastic Net

Per rispondere alla domanda "LASSO con penalità Ridge", Elastic Net viene fittato sulle 157 covariate VIF-pulite per $\alpha \in \{0,10 \ 0,25 \ 0,50 \ 0,75 \ 1,00\}$. $\alpha = 1$ è LASSO puro; $\alpha = 0$ sarebbe Ridge puro (senza selezione).

3 Risultati

3.1 Parsimonia vs accuratezza

La Figura 1 mostra la curva di trade-off ottenuta correndo cross-validation panel-aware su dimensioni del top- n da 5 fino a tutti i 157 predittori VIF-puliti.

3.2 Il modello a 25 covariate e la sua lettura sostantiva

Dopo il filtro di significatività, tutti i 25 coefficienti sono significativi a $p < 10^{-6}$ e il VIF massimo del modello finale è 6,42. La Tabella 1 li elenca ordinati per $|\hat{\beta}_j|$. Tutti i valori sono sulla scala standardizzata: $\hat{\beta}_j$ è la variazione attesa di IFC per un aumento di una deviazione standard di X_j .

Le prime 5 covariate in dettaglio

Sono i cinque predittori con l'effetto standardizzato più forte sull'IFC. Ognuno si interpreta come "un aumento di una deviazione standard della covariata cambia l'IFC di $\hat{\beta}_j$ punti". Visto che la scala IFC è $\sim 100 \pm 4$, un coefficiente di ± 1 è un effetto rilevante.

1. **reddito_26000_55000** ($\hat{\beta} = -1,03$). Massa di contribuenti che dichiarano un reddito tra 26 000 e 55 000, espressa per abitante. È un proxy della dimensione della classe media locale. Una deviazione standard in più di densità di classe media riduce l'IFC di circa un punto: la classe media locale è il singolo driver protettivo più forte della fragilità comunale.
2. **numero_contribuenti** ($\hat{\beta} = -0,78$). Numero totale di contribuenti dichiaranti per abitante. *Perché non è ridondante con la variabile precedente.* Le prime due covariate sembrano simili, ma misurano cose diverse: **reddito_26000_55000** cattura la *composizione* del reddito




Figura 1: R^2 out-of-sample in funzione del numero di covariate mantenute dal ranking VIF-pulito. Ogni punto è la media su 25 fold di cross-validation panel-aware; le barre d'errore sono ± 1 deviazione standard tra fold. La linea rossa tratteggiata segna l' R^2 del benchmark originale a 191 covariate; la linea verticale punteggiata segna il nostro $n_{\text{final}} = 25$. Il "gomito" della curva sta tra 20 e 25: spostarsi da 25 a 30 guadagna solo $+0,004$ di R^2 , mentre spostarsi da 25 a 15 costa circa $0,03$.

Variabile	$\hat{\beta}_{\text{std}}$	direzione	lettura sostantiva
reddito_26000_55000	-1,03	meno fragile	massa contribuenti classe media
numero_contribuenti	-0,78	meno fragile	densità totale contribuenti
mef_cls_0_10000_amm	+0,57	più fragile	massa di reddito dichiarato basso
reddito_pensione	+0,56	più fragile	quota reddito da pensioni
asia_ul_f_w0_9	-0,53	meno fragile	densità piccole imprese edili
asia_ul_g_w0_9	-0,49	meno fragile	densità piccolo commercio
asia_add_c_w0_9	-0,48	meno fragile	occupazione piccola manifattura
frame_industria_VA_per_addetto	-0,47	meno fragile	produttività industria
asia_ul_m_w0_9	-0,46	meno fragile	densità piccoli studi professionali
frame_servizi_VA_per_addetto	-0,45	meno fragile	produttività servizi
frame_totale_retribuzione_su_VA	-0,44	meno fragile	quota retribuzioni sul VA
lacc_mean	+0,43	più fragile	indice di accessibilità locale
asia_add_c_w10_49	-0,38	meno fragile	occupazione media manifattura
bonus_trattamento	-0,34	meno fragile	densità beneficiari bonus retributivi
asia_add_s_w0_9	-0,34	meno fragile	occupazione piccoli altri servizi
mef_cls_75000_120000_freq	-0,34	meno fragile	quota contribuenti redditi alti
mef_cls_55000_75000_freq	-0,31	meno fragile	quota contribuenti redditi medio-alti
employee_concentration	-0,27	meno fragile	indice di concentrazione occupazionale
asia_ul_q_w0_9	-0,23	meno fragile	densità piccoli servizi sanitari
eta_media_media_donne	-0,22	meno fragile	età media dipendenti pubbliche
asia_ul_i_w0_9	-0,20	meno fragile	densità piccola ricezione
Esercizi_complementari	-0,18	meno fragile	strutture turistiche extra-alberghiere
eta_uomini	+0,17	più fragile	età media maschi
istr_occupazione_tempo_pieno_donne	+0,17	più fragile	dipendenti pubbliche tempo pieno
no2_media_valori_annuali	+0,15	più fragile	media annua NO ₂

Tabella 1: Le 25 covariate finali dopo pruning VIF, ranking top-25 e filtro di significatività. Tutti i coefficienti sono significativi a $p < 10^{-6}$, tutti sulla scala standardizzata.

dichiarato (quanti contribuenti rientrano nella fascia media), mentre `numero_contribuenti` cattura il *livello* di partecipazione fiscale formale complessivo (quante persone pagano tasse in generale, indipendentemente dalla fascia). La loro correlazione campionaria, dopo il pruning VIF, è sotto 0,65, e un modello che usa solo una delle due perde potere predittivo apprezzabile. A livello concettuale, `numero_contribuenti` è in sostanza un proxy inverso dell'economia informale: più persone dichiarano reddito, minore è la quota di attività sommersa. Una SD in più riduce l'IFC di 0,78 punti.

3. `mef_cls_0_10000_amm` ($\hat{\beta} = +0,57$). Importo totale dichiarato nella fascia €0–€10 000, per abitante. Il segno positivo significa che più il reddito dichiarato è concentrato nella fascia più bassa, più il comune è fragile. È il proxy più diretto del disagio economico.
4. `reddito_pensione` ($\hat{\beta} = +0,56$). Quota di reddito dichiarato proveniente da pensioni, per abitante. Segno positivo: comuni il cui reddito è pesantemente basato su pensioni sono più fragili. È il canale dell'invecchiamento demografico: più pensionati, meno lavoratori attivi, minore dinamismo economico.
5. `asia_ul_f_w0_9` ($\hat{\beta} = -0,53$). Densità di unità locali piccole (0–9 dipendenti) nel settore edile (NACE F). Segno negativo: un tessuto vivace di micro-imprese edili è associato a minore fragilità. È uno dei diversi indicatori di piccole imprese nel modello (manifattura, commercio, servizi professionali) che puntano tutti nella stessa direzione.

La narrativa sostantiva è chiara e coerente: *la fragilità è governata dall'equilibrio tra dinamismo economico (massa contributiva, densità piccole imprese, produttività) e disagio economico (massa di redditi bassi, dipendenza da pensioni)*. Gli indicatori ambientali (NO_2) e di invecchiamento demografico compaiono nel modello ma con effetti più piccoli.

Nota su due nomi tecnici. Due variabili in tabella hanno nomi non autoesplicativi e meritano una breve chiarificazione.

- `lacc_mean` ($\hat{\beta} = +0,43$) è la media di un indice di *accessibilità locale* precalcolato nel dataset GRINS. Il segno positivo — più accessibilità associata a maggiore fragilità prevista — sembra controintuitivo a prima vista. La spiegazione più plausibile è che, dopo aver controllato per altre ventiquattro variabili socio-economiche, ciò che resta in `lacc_mean` è un segnale residuo di urbanizzazione/densità non assorbito dal resto del modello. L'interpretazione sostantiva va presa con cautela; per affermazioni forti su questo coefficiente conviene consultare il dizionario dati di GRINS V3 per la costruzione esatta della variabile.
- `employee_concentration` ($\hat{\beta} = -0,27$) è un indice di concentrazione tipo Herfindahl dell'occupazione tra settori. Riportiamo il coefficiente standardizzato come stimato; una lettura sostantiva rigorosa rimanda anch'essa a un controllo della definizione della variabile.

Le restanti 23 variabili hanno nomi e effetti trasparenti, e costituiscono la base della discussione qui sopra.

3.3 Cross-check Elastic Net

La Tabella 2 riporta la dimensione di selezione e l'errore CV per i cinque valori di α sul set VIF-pulito. La Figura 2 mostra le stesse informazioni graficamente.

3.4 Estensione con mixed model

La Tabella 3 riporta l' R^2 out-of-sample di ogni variante su entrambi i set di covariate. La Figura 3 visualizza gli stessi numeri come bar chart.

α	# selezionate	λ_{1se}	MSE CV
0,10 (verso Ridge)	124	0,108	3,512
0,25	111	0,060	3,526
0,50	114	0,028	3,520
0,75	88	0,028	3,546
1,00 (LASSO puro)	93	0,019	3,537

Tabella 2: Confronto Elastic Net sul set di 157 covariate VIF-pulite.




Figura 2: Numero di covariate selezionate da Elastic Net a λ_{1se} per cinque valori del parametro di mix α . $\alpha = 1$ è LASSO puro; $\alpha = 0$ sarebbe Ridge puro (senza selezione di variabili). Su tutto l'intervallo, l'MSE CV varia di meno dell'1% (Tabella 2) e le dimensioni di selezione sono comprese tra 88 e 124. Su una matrice di feature già ripulita dalla collinearità forte, la scelta del regolarizzatore non è quindi critica: LASSO è un default ragionevole.

Modello	R^2 (191 cov, vecchio)	R^2 (25 cov, nuovo)	Δ
Linear model (no random effect)	0,826	0,784	-0,042
M_{tax}	0,829	0,784	-0,045
M_{geo}	0,846	0,815	-0,031
$M_{geo+tax}$	0,846	0,812	-0,034
$M_{geo,nested}$	0,853	0,818	-0,035

Tabella 3: R^2 del modello lineare e dei mixed model sui set di covariate da 191 e da 25, valutati con la stessa cross-validation panel-aware a 5 fold.

La macroclasse è ridondante con la geografia. $M_{geo+tax}$ è statisticamente indistinguibile da M_{geo} . Una volta che la regione è nel modello, la macroclasse GRINS non aggiunge nulla. È l'evidenza formale che la macro-tassonomia e la macro-struttura geografica dell'Italia catturano la stessa informazione.

Componenti di varianza e correlazione intra-classe. Il miglior mixed model, $M_{geo,nested}$, decompone la varianza residua dell'IFC dopo i 25 fixed effects in tre pezzi:

$$\hat{\sigma}_{regione} = 1,22, \quad \hat{\sigma}_{provincia|regione} = 0,50, \quad \hat{\sigma}_{residuo} = 1,75 \quad (\text{tutti in unità IFC}). \quad (7)$$

In termini chiari, dopo aver controllato per le 25 covariate, le *regioni* si discostano dalla media nazionale di circa $\pm 1,2$ punti IFC; le *province* dentro la stessa regione si discostano dalla media




Figura 3: R^2 out-of-fold di ogni modello considerato, colorato per set di covariate. Le barre sono R^2 medio su 25 fold di cross-validation panel-aware; le barre d'errore sono ± 1 SD tra fold. Due osservazioni emergono. Primo: il guadagno relativo del mixed model geografico sul baseline lineare è leggermente più grande con 25 covariate (+0,034, da 0,784 a 0,818) che con 191 (+0,027). Con meno fixed effects, più varianza residua è disponibile per essere assorbita dai random intercept regionali/provinciali. Secondo: il mixed model parsimonioso chiude il divario con il benchmark originale a 191 covariate a soli $-0,007$. In pratica, un modello leggibile a 25 covariate più un random intercept geografico annidato funziona praticamente come un LASSO black-box a 191 covariate.

regionale di ulteriori $\pm 0,5$ punti IFC; e dentro una singola provincia il rumore residuo ha una deviazione standard di $\pm 1,75$ punti IFC. La correlazione intra-classe corrispondente è $ICC = (\sigma_{\text{regione}}^2 + \sigma_{\text{provincia|regione}}^2) / (\sigma_{\text{regione}}^2 + \sigma_{\text{provincia|regione}}^2 + \sigma_{\text{resid}}^2) = 0,36$. Circa il trentasei per cento della varianza non spiegata dai fixed effects è concentrata *tra* gruppi (regioni e province), e solo circa il sessantaquattro per cento è rumore genuinamente entro-provincia. È quello che dà ai random intercept il loro mordente predittivo.

3.5 Diagnostica spaziale dei residui

Abbiamo ricalcolato il Moran's I sui residui del nuovo $M_{\text{geo,nested}}$ con gli stessi pesi kNN-5:

$$I = 0,234, \quad p < 0,001 \text{ (Monte Carlo, 999 permutazioni).}$$

Essenzialmente identico al $I = 0,231$ originale ottenuto con 191 covariate. La struttura spaziale residua non è quindi un artefatto del set di covariate: è una caratteristica genuina della fragilità comunale italiana, e indica che un futuro modello spaziale esplicito (Conditional Autoregressive, Simultaneous Autoregressive, o Gaussian process) è il prossimo passo naturale.

3.6 Mappa dei residui

La Figura 4 mappa i residui del modello lineare parsimonioso a livello comunale.

Residuals of the parsimonious 25-covariate model
Red = under-predicted (model too optimistic) | Blue = over-predicted




Figura 4: Residui del modello lineare parsimonioso a 25 covariate, mediati su 2019 e 2021. Le aree rosse sono comuni il cui IFC osservato è più alto di quanto il modello predice (più fragili di quanto gli indicatori suggerirebbero); le aree blu sono l'opposto. La scala colori è cappata a ± 5 punti IFC, che sulla scala IFC di $\sim 100 \pm 4$ corrisponde a circa $\pm 5\%$ della media. Visivamente, la mappa mostra residui positivi concentrati nella Sicilia orientale, sull'Appennino calabrese, in parti di Puglia e Sardegna, e in valli alpine isolate; residui negativi lungo le pedemontane settentrionali, nella pianura Padana interna, e nell'Italia centrale. È lo stesso pattern Nord-Sud che i random intercept di regione/provincia del mixed model quantificano formalmente, ed è la controparte visiva del risultato Moran's I .

4 Oltre l' R^2 : calibrazione, incertezza, qualità del modello

L' R^2 misura solo quanta varianza viene spiegata. Tre altre qualità contano e sono ora verificate esplicitamente: *il modello è biased in media dentro ciascun bin di predizione?* (calibrazione), *quanto è largo l'intervallo di predizione empirico?* (incertezza), e *come si confronta il modello in base a un criterio che penalizza la complessità?* (AIC/BIC).

4.1 Calibrazione

Abbiamo suddiviso le predizioni cross-validate in decili e calcolato la media dell'IFC osservato dentro ciascun bin. Un modello perfettamente calibrato avrebbe ogni bin centrato sulla retta $y = x$.




Figura 5: Calibrazione del modello parsimonioso. Ogni punto blu è un decile di IFC predetto: la sua coordinata orizzontale è la media del valore predetto nel decile, la verticale è la media del valore osservato nello stesso decile. Le barre d'errore sono ± 1 standard error della media osservata. La linea grigia tratteggiata è l'ideale $y = x$. I dieci punti stanno vicini alla linea entro le barre d'errore, quindi la calibrazione è nel complesso buona. Guardando più da vicino si nota un piccolo pattern sistematico: il decile più basso è sottostimato di circa 0,6 IFC, i decili 2–5 sono sovrastimati di 0,15–0,30, e i decili più alti tornano a bias quasi nullo. Questa forma a S residua è la controparte in-sample dell'effetto di regressione verso la media discusso nella sotto-sezione successiva; è piccola in magnitudo (sempre entro una standard error della media osservata) ma è presente e la riportiamo apertamente.

4.2 Dove vivono gli errori?

Una vista complementare è la distribuzione dei residui per decile dell'IFC *osservata*. Se il modello fosse non-biased su tutto il range, ogni box della Figura 6 dovrebbe essere centrato su zero.

4.3 Incertezza predittiva

Abbiamo calcolato la distribuzione empirica dei residui out-of-sample sui 25 fold CV panel-aware e ricavato un intervallo di predizione al 95 %.

Metriche riassuntive di incertezza. Le seguenti metriche basate sulla correlazione complementano l' R^2 :

- correlazione di Pearson tra osservato e predetto: 0,885;
- correlazione di rango di Spearman: 0,890 (l'ordinamento è preservato);
- coefficiente di concordanza di Lin: 0,879 (leggermente sotto Pearson per il piccolo bias di regressione verso la media visibile in Figura 6).

4.4 Criteri di informazione

Più bassi sono AIC e BIC, migliore è il trade-off tra fit e complessità. $\Delta AIC > 10$ tra due modelli è convenzionalmente "evidenza decisiva" a favore del modello a AIC più basso.




Figura 6: Box plot dei residui CV per decile dell'IFC osservato. Emerge un pattern chiaro: il modello sovrastima leggermente l'IFC per i comuni meno fragili (residuo medio $\approx -1,5$ nel decile 1) e sottostima leggermente l'IFC per i più fragili (residuo medio $\approx +1,8$ nel decile 10). È il classico effetto di *regressione verso la media*: una conseguenza matematica dell'avere $R^2 < 1$ in qualsiasi modello lineare. I valori predetti sono inevitabilmente compressi verso la media di una frazione pari a $1 - R^2 \approx 22\%$. *Non* è un bug. La SD dei residui è costante tra decili (omoscedasticità rispettata), nessuna assunzione viene violata, e l'ordinamento dei comuni (Spearman $\rho = 0,89$) è preservato. L'implicazione pratica è che le stime puntuali per comuni molto fragili o molto robusti vanno lette come conservative.

Modello	AIC	BIC	R^2 CV	ICC
$M_{\text{geo,nested}}$	62 908	63 131	0,818	0,362
$M_{\text{geo}+\text{tax}}$	63 444	63 667	0,812	0,358
M_{geo}	63 487	63 702	0,815	0,348
M_{tax}	65 585	65 800	0,784	0,003
LM parsimonioso	65 668	65 876	0,784	—

Tabella 4: Qualità del modello combinando criterio complexity-aware (AIC, BIC), criterio predittivo out-of-sample (R^2 CV) e correlazione intra-classe. Il mixed model geografico annidato vince su AIC, BIC e R^2 predittivo con margini schiacciati ($\Delta\text{AIC} > 500$ sul secondo migliore, $\Delta\text{AIC} > 2700$ sul lineare puro). L'ICC di M_{tax} crolla a 0,003: i gruppi della macroclasse GRINS non portano sostanzialmente varianza residua, è la controparte formale della ridondanza vista nella Tabella 3.

5 Normalità dei residui

I mixed model assumono residui Gaussiani e random intercept Gaussiani. Verifichiamo entrambi.




Figura 7: Distribuzione empirica dei residui out-of-sample. Le linee rosse tratteggiate segnano i quantili 2,5 % e 97,5 % della distribuzione: $-3,75$ e $+4,04$ punti IFC. L'intervallo di predizione empirico al 95 % è quindi circa ± 4 punti IFC (per una larghezza totale di 7,79). Sulla scala IFC di $\sim 100 \pm 4$, corrisponde a circa $\pm 4\%$ della media.

5.1 Residui del modello lineare

Statistica	Valore
Media dei residui	≈ 0
SD dei residui	1,93
Asimmetria	0,35
Excess kurtosis (Normale: 0)	2,31
Anderson–Darling p	$< 10^{-23}$
Jarque–Bera p	$< 10^{-300}$
Shapiro–Wilk W (campione di 5 000)	0,982

Tabella 5: Diagnostica di normalità sui residui del modello lineare parsimonioso.

I test formali rifiutano tutti la normalità, ma è il comportamento *atteso* a $n = 15\,780$: qualsiasi piccola deviazione diventa rilevabile. Le statistiche di forma interpretabili raccontano una storia più mite: i residui sono quasi simmetrici (asimmetria 0,35) e moderatamente a code pesanti (excess kurtosis 2,31). La statistica W di Shapiro–Wilk, 0,982, è molto vicina al valore normale perfetto di 1.

5.2 Random intercept del mixed model

Anche i Best Linear Unbiased Predictors (BLUP) dei random intercept regionali e provinciali hanno una distribuzione Gaussiana assunta. La Figura 10 mostra i loro Q–Q plot.




Figura 8: Q-Q plot dei residui standardizzati del modello lineare parsimonioso contro la Normale standard. I punti cadono sulla retta tratteggiata sulla maggior parte della distribuzione; piccole deviazioni nelle code estreme riflettono la moderata excess kurtosis. Non c'è un pattern a S che indicherebbe asimmetria, né un plateau che indicherebbe troncamento. La distribuzione è approssimativamente Normale con code leggermente più pesanti.




Figura 9: Istogramma dei residui (blu) sovrapposto alla densità Normale teorica (rossa) con stessa media e SD. I due profili coincidono nella regione centrale; l'istogramma ha leggermente meno valori vicino a zero e leggermente di più nelle code di quanto la Normale predirebbe. È la controparte visiva del risultato di excess kurtosis nella tabella sopra.




Figura 10: Q-Q plot dei BLUP di $M_{\text{geo_nested}}$. Ogni pannello è un livello di raggruppamento: regioni ($n = 20$) e coppie regione/provincia ($n = 107$). I punti stanno sulla diagonale tratteggiata: i random intercept sono approssimativamente Normali, l'assunzione di `lme4` è soddisfatta.

	Report precedente	Questo report
Set di covariate	191 (LASSO)	25 (VIF + ranking + sig.)
Superficie nel modello	sì ($\beta_{\text{std}} = -0,38$)	no (esclusa a monte)
R^2 predittivo	0,826 (LM)	0,784 (LM)
R^2 estensione LMM (best)	0,853	0,818
Guadagno LMM su baseline LM	+0,027	+0,034
Moran's I sui residui	0,231	0,234
Check multicollinearità	qualitativo (solo PM)	VIF iterativo
Significatività predittori	maggior parte	tutti 25 a $p < 10^{-6}$
Check di calibrazione	no	sì
Intervallo di predizione	no	7,79 IFC ($\pm 4\%$)
Normalità residui	basica	QQ plot + AD + JB + QQ BLUP
Leggibile in un poster	no	sì

Tabella 6: Confronto side-by-side del benchmark originale e dell'attuale estensione parsimoniosa.

6 Confronto con il report precedente

7 Conclusione

Il modello parsimonioso a 25 covariate risponde a ogni preoccupazione che il docente ha sollevato. La multicollinearità è rimossa dal pruning VIF iterativo ($\max \text{VIF} = 6,4$ alla fine). Il numero totale di predittori scende da 191 a 25, tutti significativi a $p < 10^{-6}$. Il cross-check Elastic Net conferma che la scelta di LASSO rispetto a Ridge non ha impatto materiale su un input VIF-pulito. La superficie totale, descrittore statico che il docente ha chiesto di rimuovere, è esclusa a monte. L'estensione mixed-model sulla gerarchia geografica annidata recupera la maggior parte dell' R^2 predittivo che il modello lineare parsimonioso perde, raggiungendo 0,818 — solo 0,007 sotto il benchmark originale a 191 covariate. La diagnostica spaziale è robusta al cambio del set di covariate ($I = 0,234$, identico al precedente 0,231), confermando che la modellazione spaziale esplicita è il prossimo passo naturale. La calibrazione è eccellente in media, gli intervalli di predizione sono attorno al $\pm 4\%$ della media IFC, e la normalità dei residui è soddisfatta entro i

limiti visibili nei Q-Q plot. Sostantivamente, la fragilità è governata dall'equilibrio tra la massa locale di redditi medi e la quota di reddito dichiarato basso o pensionato, modulata dalla densità di piccole imprese e dalla produttività settoriale.

E i modelli non-lineari? Generalised additive model, random forest, gradient boosting machine o reti neurali con quasi certezza alzerebbero l' R^2 sopra lo 0,818 qui riportato. Sono volutamente fuori scope di questo deliverable per due motivi. Primo: la consegna del progetto chiedeva un *benchmark lineare* discutibile coefficiente per coefficiente; il modello parsimonioso assolve esattamente quel ruolo. Secondo: la diagnostica dei residui suggerisce che la varianza non spiegata restante vive in due posti che il semplice passaggio a una forma funzionale non-lineare non affronta: l'autocorrelazione spaziale fine rilevata dal Moran's I e la varianza tra gruppi già catturata dai random intercept. Un'estensione non-lineare sensata dovrebbe essere combinata con un modello spaziale esplicito, e la lasciamo a un follow-up.