

Da PCA a PCR a PLS: un'estensione del benchmark lineare IFC tramite riduzione di dimensionalità

Progetto di Statistica Applicata — Report di estensione PCR

Sommario

Questo report risponde a un'osservazione specifica del docente (*“PCR non PCA?”*) estendendo l'analisi descrittiva delle componenti principali del progetto (script 02 / 02b / 02c) in una Principal Component Regression a fini predittivi. Il lavoro è organizzato in tre passi. Primo: applichiamo la PCR ai 326 predittori GRINS V3 ingegnerizzati usati dal benchmark LASSO e dal modello parsimonioso. Secondo: applichiamo la PCR ai 12 indicatori IFC che costituiscono l'indice stesso, in un esercizio volutamente quasi tautologico che usiamo come controllo di sanità sulla costruzione dell'IFC. La presenza di un residuo irriducibile di $\sim 1,3\%$ rivela che l'IFC raw *non* è una combinazione lineare pura dei dodici indicatori; lo scarto è coerente con il passaggio standard di rango percentuale che la metodologia ufficiale applica prima dell'aggregazione pesata. Terzo: aggiungiamo le Partial Least Squares (PLS) come naturale competitor information-aware della PCR. La PLS domina la PCR di circa cinque punti percentuali di R^2 a ogni K , e pareggia il benchmark LASSO a $K = 75$ senza mai offrirne l'interpretabilità. La conclusione è che LASSO resta il metodo preferito per questo problema, ma la PLS è un upper bound non-interpretabile difendibile; la PCR da sola è subottimale perché la direzione predittiva nei nostri dati non coincide con la direzione di massima varianza.

1 Perché è stata aggiunta un'estensione PCR

La cascata descrittiva di PCA del progetto (script 02_pca.R, 02b_pca_all.R, 02c_pca_presentation.R) decompone i 12 indicatori IFC in componenti principali e caratterizza come la loro varianza si distribuisce tra anni e tra indicatori. Non utilizza, però, le componenti risultanti per fare predizione. Il docente ha fatto notare che l'estensione naturale di quell'analisi descrittiva è una Principal Component Regression: *usare le PC come regressori in un modello per l'IFC*.

Questo è metodologicamente diverso dal benchmark LASSO e dal modello parsimonioso documentati in `reports/parsimonious_extension`. Quei due approcci costruiscono un modello sulle *variabili originali* GRINS, dopo o penalizzazione ℓ_1 o pruning VIF + ranking + filtro di significatività. La PCR sostituisce l'intero passo di selezione con una *riduzione di dimensionalità*: prende un piccolo insieme di nuove variabili (le PC), definite come combinazioni lineari di *tutte* le originali, e regredisce il target su di esse.

Le domande a cui vogliamo rispondere sono:

- Come si comporta la PCR sulle stesse 326 features GRINS, out-of-sample, rispetto al benchmark LASSO e al modello parsimonioso?
- La PCR applicata direttamente ai 12 indicatori IFC riproduce l'IFC, e se no, cosa rivela il residuo?
- La sottoperformance della PCR, quando si verifica, è una proprietà del metodo o dei nostri dati? La PLS risolve la questione.

2 Metodo

2.1 Notazione e cross-validation panel-aware

In tutto il report, $\mathbf{X} \in \mathbb{R}^{n \times p}$ è la matrice dei predittori standardizzati, $\mathbf{y} \in \mathbb{R}^n$ è il target IFC, $n = 15782$ è il numero di osservazioni comune-anno, e K è il numero di componenti trattenute. Tutte le metriche di performance usano la stessa **cross-validation panel-aware a 5 fold** del resto del progetto: ogni comune (sia le righe del 2019 sia quelle del 2021) sta in un singolo fold, così il set di test contiene sempre comuni che il modello non ha mai visto. Riportiamo media e deviazione standard di R^2 tra i fold.

Un indicatore binario $\text{year2021}_i \in \{0, 1\}$ è incluso come effetto fisso separato in ogni regressione ma è escluso dalla costruzione delle componenti principali / PLS, perché una variabile binaria distorce le direzioni principali ed è concettualmente un controllo, non contenuto.

2.2 Principal Component Regression

La PCR procede in due passi. Primo, la matrice di covarianza campionaria di $\mathbf{X}$ viene diagonalizzata:

$$\frac{1}{n} \mathbf{X}^\top \mathbf{X} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top, \quad \mathbf{Z} = \mathbf{X} \mathbf{V}. \quad (1)$$

Le colonne di $\mathbf{V}$ sono le direzioni principali; le colonne di $\mathbf{Z}$ sono gli score delle componenti principali. Gli autovalori in $\mathbf{\Lambda}$ sono ordinati in modo decrescente, quindi la componente j porta la j -esima quota più alta di varianza totale in $\mathbf{X}$. Secondo: una regressione lineare di y sulle prime K componenti più il fixed effect anno viene fittata con OLS:

$$\widehat{\text{IFC}}_i = \beta_0 + \sum_{j=1}^K \beta_j Z_{ij} + \gamma \text{year2021}_i. \quad (2)$$

La proprietà cruciale di (1) è che essa *ignora y*: le direzioni principali sono quelle di massima varianza in $\mathbf{X}$, non quelle di massimo contenuto predittivo per y . La PCR funziona bene solo quando le due direzioni coincidono.

2.3 Partial Least Squares

La PLS è l'analogo predittivo naturale della PCR: sceglie lo stesso tipo di componenti ma usando y a ogni passo. La componente j è definita come la combinazione lineare di $\mathbf{X}$ che massimizza la covarianza campionaria con il (residuo di) y date le componenti precedenti. Formalmente, la prima direzione PLS risolve

$$\mathbf{w}_1 = \arg \max_{\|\mathbf{w}\|=1} \text{Cov}(\mathbf{X}\mathbf{w}, \mathbf{y}), \quad (3)$$

e le direzioni successive iterano dopo aver deflattato sia $\mathbf{X}$ sia $\mathbf{y}$ della varianza già catturata. Usiamo `pls::pls` e aggiungiamo il fixed effect anno alla predizione finale come per la PCR.

2.4 Tre pipeline concrete

Eseguiamo tre analisi concrete:

- **Script 18 (PCR su GRINS V3).** $\mathbf{X}$ è la matrice GRINS ingegnerizzata da 326 feature, la stessa usata dal benchmark LASSO.
- **Script 18b (PCR sui 12 indicatori IFC).** $\mathbf{X}$ è la matrice 12-indicatori da cui l'IFC ufficiale è costruito. Vengono applicati gli stessi flip di polarità dello script 02. Il target è il valore IFC raw.
- **Script 18c (PLS vs PCR su GRINS V3).** Sia PCR sia PLS vengono fittate sulla stessa matrice GRINS ingegnerizzata dello script 18 e confrontate agli stessi valori di K .

3 Risultati

3.1 PCR su GRINS V3: la riduzione di dimensionalità è subottimale

La Figura 1 mostra lo scree plot della PCA sulle 326 feature ingegnerizzate. La varianza è distribuita su molte componenti: ne servono 50 per raggiungere il $\sim 60\%$ del totale, e 100 per circa l'80%.




Figura 1: Scree plot della PCA sulla matrice GRINS V3 ingegnerizzata (prime 50 PC). Barre blu: varianza marginale per PC. Linea rossa: varianza cumulata.

La Tabella 1 e la Figura 2 riportano l' R^2 out-of-sample della PCR in funzione di K . Le linee tratteggiate orizzontali segnano il benchmark LASSO ($R^2 = 0,825$) e il modello lineare parsimonioso ($R^2 = 0,784$).

K	R^2	RMSE	MAE	varianza cumulata
5	0,69 (approssimato)	2,32	1,77	12 %
25	0,771	2,00	1,50	28 %
50	0,778	1,96	1,48	41 %
75	0,779	1,96	1,47	50 %
100	0,787	1,92	1,45	59 %

Tabella 1: PCR sulla matrice GRINS a 326 feature, CV panel-aware a 5 fold. Anche con cento componenti principali, la PCR resta sotto il modello lineare parsimonioso (che usa solo 25 variabili originali) e quattro punti di R^2 sotto il benchmark LASSO.

Due letture dello stesso grafico. Primo: su base assoluta, la PCR non riesce a pareggiare il benchmark LASSO nemmeno con cinque volte tante componenti: 100 PC raggiungono 0,787, ancora $-0,038$ sotto il LASSO a 0,825. Secondo: su base *per-componente*, la PCR è ancora meno efficiente di quanto il conteggio ingenuo suggerisca. A $K = 25$ la PCR fa 0,772, circa 1,3 punti percentuali sotto il modello lineare parsimonioso sullo stesso numero di variabili originali. È la firma empirica del *disallineamento tra varianza e predizione*: le direzioni principali di $\mathbf{X}$ non sono le direzioni in cui vive il segnale IFC.




Figura 2: Curva di trade-off PCR sulle feature GRINS V3. R^2 medio out-of-sample su 25 fold di CV panel-aware, con barre d'errore di ± 1 deviazione standard. La PCR ha bisogno di circa 100 PC per raggiungere $R^2 \approx 0,787$, ancora sotto il LM parsimonioso (25 variabili, $R^2 = 0,784$) e quattro punti sotto il benchmark LASSO (191 variabili, $R^2 = 0,825$).

3.2 PCR sui 12 indicatori IFC: un controllo quasi tautologico

Gli script in cascata `02_pca.R` / `02b` / `02c` calcolano la PCA descrittiva sui 12 indicatori IFC `Ind1, \dots, Ind12`. La controparte predittiva naturale è regredire l'IFC raw sulle PC principali di quegli stessi dodici indicatori. Poiché l'IFC è costruito, almeno nominalmente, per aggregazione di quelle stesse dodici variabili, l'esercizio è prossimo alla tautologia: una regressione su tutti i dodici indicatori originali dovrebbe riprodurre l'IFC quasi esattamente.

Una scoperta sui dati. La prima esecuzione di questo script ha restituito un $R^2 = 0,982$ apparentemente incompleto. Indagando abbiamo scoperto che il file `IFC_Final_Analysis_Sorted.xlsx` contiene un piccolo numero di voci `PRO_COM` $\times$ `year` duplicate con valori IFC incoerenti (es. il comune 5122 nel 2021 compare due volte con `IFC = 100` e `IFC = 110` rispettivamente). La pipeline basata su GRINS maschera il problema implicitamente tramite un `inner join` con un pannello GRINS univoco; qui, con solo i 12 indicatori dal lato dei predittori, i duplicati emergono. Abbiamo aggiunto un passo `distinct(PRO_COM, year)` su entrambi i lati del merge prima di rieseguire.

Il restante 1,3% è informativo. Dopo la deduplica la PCR con $K = 12$ raggiunge $R^2 = 0,987$, vedi Tabella 2 e Figura 3. Il residuo 1,3% è piccolo ma non zero e non sparisce con più componenti. Ci dice che l'IFC raw non è una pura combinazione lineare dei 12 indicatori: c'è un passo non-lineare (percentile rank, normalizzazione anno-specifica o simile) che la metodologia ufficiale IFC applica prima dell'aggregazione pesata. L'esercizio PCR funziona quindi anche come diagnostico sulla costruzione dell'IFC stesso.

Un'illustrazione pulita del perché la PCR sbaglia il ranking. A $K = 4$ la PCR ha usato il 60% della varianza di $\mathbf{X}$ ma raggiunge solo $R^2 = 0,763$. Aggiungendo PC5 porta solo +7% di varianza ma +0,14 di R^2 . La quinta direzione principale è quindi molto più informativa per l'IFC di quanto la sua quota di varianza suggerirebbe. Lo stesso è vero per PC10, con una

K	R^2	varianza cumulata	guadagno marginale
1	0,648	29,5 %	—
2	0,741	43,4 %	+0,093
3	0,746	52,2 %	+0,005
4	0,763	60,1 %	+0,017
5	0,899	67,1 %	+0,136
6	0,914	74,0 %	+0,015
7	0,920	80,5 %	+0,006
8	0,932	85,9 %	+0,013
9	0,936	90,6 %	+0,003
10	0,970	94,6 %	+0,034
11	0,980	97,9 %	+0,010
12	0,987	100 %	+0,007

Tabella 2: PCR sui 12 indicatori IFC, CV panel-aware a 5 fold dopo deduplica. I guadagni di R^2 sono spettacolarmente *non-monotoni*: la PC5 da sola vale più di PC1–PC4 messe insieme, e la PC10 da sola vale più di PC6–PC9 messe insieme.




Figura 3: Curva di trade-off PCR sui 12 indicatori IFC. I due salti visibili, tra $K = 4$ e $K = 5$ e tra $K = 9$ e $K = 10$, sono la firma empirica della debolezza principale della PCR: la direzione predittiva non si allinea con le direzioni principali, quindi alcune PC "minori" portano una quota sproporzionata del contenuto predittivo per l'IFC.

discontinuità simile. È il motivo pratico per cui la PLS, che usa y per ordinare le sue componenti, è il metodo corretto per questo tipo di problema.

3.3 Confronto diretto: la PLS domina la PCR

Lo script 18c esegue PCR e PLS sulla stessa matrice GRINS a 326 feature e agli stessi valori di K . Tabella 3 e Figura 4 riportano il risultato.

Tre osservazioni. Primo: il gap PLS–PCR è stabile e sostanziale: circa cinque punti percentuali di R^2 su tutto il range di K . È molto più grande della deviazione standard tra fold ($\sim 0,01$) e quindi non è un artefatto di uno split favorevole. Secondo: la PLS a $K = 25$ fa

K	PCR R^2	PLS R^2	gap PLS – PCR
5	0,739	0,796	+0,058
10	0,761	0,810	+0,049
15	0,766	0,817	+0,051
20	0,769	0,820	+0,051
25	0,772	0,822	+0,050
30	0,776	0,823	+0,047
50	0,779	0,824	+0,045
75	0,780	0,825	+0,045
100	0,787	0,824	+0,037

Tabella 3: PCR vs PLS sulla matrice GRINS a 326 feature, CV panel-aware a 5 fold. La PLS domina la PCR di circa cinque punti di R^2 a ogni K . La PLS a $K = 25$ batte già sia il modello lineare parsimonioso sia l'estensione mixed-model; la PLS a $K = 75$ pareggia il benchmark LASSO.




Figura 4: PLS vs PCR sulle feature GRINS V3. R^2 out-of-sample su 5 fold di CV panel-aware, media ± 1 deviazione standard. La linea rossa tratteggiata è il benchmark LASSO; la linea blu tratteggiata è il modello lineare parsimonioso. La PLS raggiunge il benchmark LASSO a $K \approx 75$; la PCR non lo raggiunge mai nel range esplorato.

già 0,822, che è meglio sia del modello lineare parsimonioso a parità di complessità nominale (25 dimensioni) sia dell'estensione mixed-model $M_{\text{geo,nested}}$. La PLS in questo senso è un upper bound non-interpretabile sulla classe dei modelli lineari. Terzo: la PLS si stabilizza intorno a $K = 75$ a 0,825, sostanzialmente in pari col benchmark LASSO a 191 covariate. I due metodi raggiungono lo stesso tetto predittivo per strade diverse: LASSO seleziona, PLS combina.

4 Confronto con il resto del progetto

La Tabella 4 aggrega tutti i modelli stimati fino a ora. La PLS a $K = 25$ e l'LMM $M_{\text{geo,nested}}$ a 25 covariate sono sostanzialmente in pari, e solo marginalmente sotto il benchmark LASSO e la PLS a $K = 75$. La PCR è sistematicamente sotto questo gruppo.

Modello	dimensioni	R^2 CV	interpretabilità
Benchmark LASSO	191 var. GRINS	0,826	alta (variabili nominate)
PLS su GRINS ($K = 75$)	75 componenti	0,825	bassa (variabili mixate)
PLS su GRINS ($K = 25$)	25 componenti	0,822	bassa
LMM $M_{\text{geo,nested}}$	25 var. + RE	0,818	alta
PCR su GRINS ($K = 100$)	100 componenti	0,787	bassa
LM parsimonioso	25 var. GRINS	0,784	alta
PCR su GRINS ($K = 25$)	25 componenti	0,772	bassa
PCR su 12 IFC ($K = 12$)	12 componenti	0,987	quasi-tautologico

Tabella 4: Tutti i modelli considerati nel progetto finora, ordinati per R^2 out-of-sample all'interno del gruppo GRINS. L'ultima riga è inclusa solo per l'interpretazione diagnostica (PCR sui suoi stessi indicatori di input dell'IFC).

5 Conclusioni

La richiesta del docente di estendere la PCA descrittiva in una Principal Component Regression ha prodotto un insieme coerente di findings metodologici.

La PCR sottoperforma perché varianza e predizione non si allineano. Sia sulla matrice GRINS a 326 feature sia sulla matrice 12-indicatori IFC, la PCR deve usare componenti molto più giù nel ranking rispetto alle direzioni principali per catturare il segnale IFC. L'esempio più chiaro è il salto di +0,14 di R^2 a $K = 5$ in Figura 3: la PC5 porta il 7% della varianza di $\mathbf{X}$ ma più contenuto predittivo di PC1-PC4 messe insieme.

Il test di tautologia conferma che l'IFC non è pure-linear. La PCR sui 12 indicatori IFC si ferma a $R^2 = 0,987$, non a 1,0. L'1,3% restante non è rumore ma una non-linearità strutturale nella costruzione dell'IFC (un passo di rango percentuale o normalizzazione simile). È un utile controllo di sanità sul target stesso.

La PLS aggiusta il disallineamento ma perde interpretabilità. La PLS, che usa y nella scelta delle componenti, domina la PCR di circa cinque punti di R^2 a ogni K . La PLS a $K = 75$ pareggia il benchmark LASSO; la PLS a $K = 25$ è sostanzialmente in pari con il mixed model geografico annidato. Il benchmark LASSO non è quindi un'accidente speciale della penalità: qualsiasi proiezione lineare 75-dimensionale ben scelta delle feature GRINS raggiunge lo stesso tetto predittivo. Quello che il LASSO compra è l'*interpretabilità*: 25 covariate nominate con segni espliciti e effetti standardizzati, invece di 25 o 75 combinazioni lineari di tutte le 326 feature.

Take-away per il progetto. La pipeline LASSO + LMM mantiene il suo posto come deliverable preferito. La PCR è documentata qui come controllo metodologico (è ciò che si ottiene trattando la riduzione di dimensionalità come sostituto della selezione di variabili), e la PLS è documentata come il miglior upper bound lineare non-interpretabile. La scelta tra LASSO e PLS a $K = 75$ è essenzialmente una scelta tra variabili interpretabili e un modello illeggibile ma leggermente più grande: nel nostro contesto raggiungono la stessa accuratezza predittiva.