

Guida alla presentazione: il filo narrativo completo del progetto di modellazione predittiva dell'IFC

Progetto di Applied Statistics — Note di preparazione alla presentazione

Sommario

Questo documento non è un report tecnico: è un supporto per parlare. Ripercorre l'intero progetto nell'ordine in cui va raccontato a voce, spiega ogni numero che compare sul poster, dichiara esplicitamente cosa è stato volutamente escluso e perché, e si chiude con una sezione di domande-e-risposte anticipate, in modo che nessuna domanda ragionevole del pubblico colga il presentatore impreparato. Leggere le sezioni 1–7 per provare la presentazione; leggere la sezione 8 la sera prima per provare la difesa.

1 La tesi in una frase

La fragilità comunale italiana è prevedibile e leggibile da un piccolo gruppo di indicatori socio-economici, ma una componente geografica residua mostra che il fenomeno non è puramente individuale — è anche spaziale.

Tutto il resto del progetto sostiene questa frase. Se di tutta la presentazione dovesse sopravvivere una sola frase, dovrebbe essere questa.

2 La domanda di ricerca e perché conta

L'Italian Fragility Composite Index (IFC) è un indice ufficiale a livello comunale. Il progetto pone due domande:

1. L'IFC può essere spiegato/predetto statisticamente da indicatori socio-economici indipendenti (il panel GRINS V3)?
2. Se sì, cosa guida davvero la fragilità comunale, e la spiegazione è puramente socio-economica o la geografia gioca un ruolo indipendente?

Questo conta perché se un piccolo insieme di indicatori leggibili riesce a ricostruire la maggior parte della varianza di un indice di fragilità ufficiale, quell'indice può essere monitorato a basso costo tra una pubblicazione ufficiale e l'altra, e i driver identificati diventano leve candidate per le politiche pubbliche.

3 I dati, in un paragrafo

Target: valori IFC grezzi per il 2019 e il 2021, da `IFC_Final_Analysis_Sorted.xlsx`; coincide con i decili MFI ufficiali nel 95.6% dei casi, confermando che è un proxy fedele dell'indice realmente usato dai decisori pubblici. **Predittori:** il panel comunale GRINS V3, 549 colonne grezze, trasformate in 326 covariate candidate (i conteggi normalizzati per la popolazione più una trasformazione $\log_{1p}$, i conteggi negativi normalizzati solo per la popolazione, le variabili di dimensione $\log$ -trasformate, i tassi lasciati invariati, tutto winsorizzato al 1°/99° percentile per limitare l'influenza dei comuni anomali). **Campione:** 15.782 osservazioni, 7.886 comuni unici, due anni (2019, 2021). La cross-validation è sempre fatta dividendo comuni interi nei fold, mai

per riga — dividere per riga farebbe finire l’osservazione 2019 di un comune nel fold di training mentre la sua gemella 2021 finisce nel fold di test, facendo trapelare informazione e gonfiando l’ R^2 in modo silenzioso.

4 La pipeline di modellazione, raccontata come sequenza di domande

Ogni passo esiste perché risponde a una domanda lasciata aperta dal passo precedente. Va raccontata in questo ordine.

Passo 1 — Quanto si può spiegare in assoluto?

Una regressione LASSO (CV a 10 fold, λ_{1se}) è eseguita su tutte le 326 covariate candidate. Ne seleziona 191. R^2 out-of-sample = 0.825 (CV ripetuta 5×5 panel-aware, 25 fold totali). Questo è il *benchmark*: il tetto di ciò che un modello lineare può spiegare con questo set di feature. La prima reazione del prof era corretta: 191 covariate non si possono discutere una per una in nessuna presentazione.

Passo 2 — Lo stesso risultato si può raccontare con meno variabili?

Una pipeline iterativa riduce le 191 covariate a un set parsimonioso di 25, esplicito e riproducibile:

1. **Potatura VIF**: si elimina la covariata con il Variance Inflation Factor più alto, si ricalcola, si ripete, finché tutti i VIF restanti sono sotto 10 (34 covariate eliminate così).
2. **Ranking top-N**: i superstiti vengono ordinati per effetto standardizzato $|\beta \cdot SD|$ e si tengono i primi 25 — è ciò che rende le variabili comparabili tra loro nonostante vivano su scale naturali diverse.
3. **Filtro di significatività**: ogni covariata che risulta non significativa una volta che le altre 24 sono nel modello viene automaticamente sostituita dal candidato successivo nel ranking, ripetendo finché tutte le 25 sono significative.

Una decisione sostanziale esplicita precede tutti e tre i passi: la superficie comunale grezza viene esclusa a priori, su richiesta diretta del prof, perché una volta che ogni altra covariata è espressa come densità o tasso per-capite, un descrittore geografico statico come la superficie totale non è di per sé un driver di fragilità — è una variabile di scala che il resto della pipeline controlla già implicitamente.

Risultato: 25 covariate, tutte significative a $p < 10^{-6}$, VIF massimo = 6.4. R^2 out-of-sample = 0.784 — una perdita controllata di soli 0.041 rispetto al benchmark a 191 covariate, per una riduzione dell’87% nella dimensione del modello.

Passo 3 — La geografia aggiunge qualcosa che le 25 covariate non colgono?

Un modello lineare misto aggiunge una struttura di intercette casuali sopra gli stessi 25 effetti fissi:

$$IFC_i = \beta_0 + \sum_{j=1}^{25} \beta_j X_{ji} + u_{r(i)} + v_{p(i)|r(i)} + \varepsilon_i,$$

$$u_r \sim \mathcal{N}(0, \sigma_R^2), \quad v_{p|r} \sim \mathcal{N}(0, \sigma_P^2),$$

con r che indicizza 20 regioni e p che indicizza 107 provincie nidificate nelle regioni. Sono state stimate e confrontate quattro varianti (solo regione, regione/provincia nidificate, raggruppamento basato sulla tassonomia GRINS, e la combinazione di geografia e tassonomia); il modello

geografico nidificato è il migliore dei quattro. R^2 out-of-sample = 0.818 — a 0.007 dal benchmark a 191 covariate, recuperando quasi tutta l'accuratezza persa diventando parsimoniosi. La correlazione intra-classe attribuibile alla geografia è circa il 36%: più di un terzo della varianza residua dopo i 25 effetti fissi è spiegata da in quale regione e provincia si trova un comune, non dal valore di nessuna covariata.

Passo 4 — Quel segnale geografico è già esaurito, o manca ancora qualcosa?

Il Moran's I globale sui residui del modello nidificato, usando una matrice di pesi spaziali kNN-5 simmetrizzata:

$$I = 0.234, \quad p < 0.001.$$

È positivo e altamente significativo: *dopo* aver controllato per 25 covariate socio-economiche e intercette casuali regione/provincia, i comuni vicini condividono ancora fragilità inspiegata. La geografia non è del tutto assorbita dai confini amministrativi. La scomposizione locale LISA di un compagno, sugli stessi residui e stessi pesi, recupera indipendentemente $I = 0.236$ — confermando il numero globale — e lo localizza: 598 comuni formano cluster significativi "High-High" (sotto-predetti, circondati da altri comuni sotto-predetti), 554 formano cluster "Low-Low", e 6.418 non mostrano un pattern locale significativo.

Qui va inserito un limite esplicito e onesto: i modelli autoregressivi spaziali espliciti (SAR/CAR) sono stati tentati come passo successivo naturale, ma non sono convergiti in un tempo di calcolo praticabile su questa dimensione del dataset, e sono stati abbandonati piuttosto che riportati con numeri non attendibili. Questo va dichiarato apertamente, non nascosto.

Passo 5 — Il modello è statisticamente affidabile, o solo un R^2 fortunato?

Una batteria di diagnostiche aggiuntive, riassunta brevemente perché appartiene al report più che al poster: calibrazione per decile (Pearson/Spearman/CCC di Lin = 0.885/0.890/0.879), un intervallo di predizione empirico al 95% di ampiezza 7.79 punti IFC, confronto AIC/BIC che conferma la preferenza per il modello nidificato, e diagnostica di normalità dei residui (skewness 0.35, curtosi in eccesso 2.31, Shapiro-Wilk $W = 0.982$) che mostra una deviazione lieve ma reale dalla normalità, documentata per intero con QQ plot nel report dedicato all'estensione parsimoniosa.

Passo 6 — Esiste un modo fondamentalmente diverso di arrivare alla stessa accuratezza?

In risposta diretta all'osservazione del prof "PCR, non PCA":

- **PCR sulle 326 feature GRINS:** R^2 migliore = 0.787 a $K = 100$ componenti — sotto sia il modello parsimonioso sia il benchmark. Le componenti principali sono scelte per massimizzare la varianza in X , non il potere predittivo su Y ; qui le direzioni non coincidono.
- **PCR sui 12 indicatori IFC grezzi** (le stesse componenti usate dalla cascata di PCA descrittiva): $R^2 = 0.987$ a $K = 12$, cioè usando *tutta* l'informazione. Il residuo dell'1.3% è informativo, non rumore: rivela che la costruzione ufficiale dell'IFC include uno step non lineare (quasi certamente una trasformazione a rango percentile) oltre a un'aggregazione lineare pesata delle sue 12 componenti.
- **PLS contro PCR, testa a testa**, sulla stessa matrice a 326 feature: PLS (che sceglie le componenti per covarianza con Y , non per sola varianza di X) domina PCR di circa 5 punti percentuali di R^2 a ogni numero di componenti. PLS a $K = 75$ raggiunge $R^2 = 0.825$, pareggiando quasi esattamente il benchmark LASSO a 191 covariate (0.826).

Conclusione di questo passo: la riduzione dimensionale *può* pareggiare l'accuratezza di LASSO, ma solo sacrificando l'interpretabilità — 75 componenti latenti non hanno un significato sostanziale individuale, mentre le 191 (o le 25 parsimoniose) di LASSO sono variabili nominate, con segno, leggibili. LASSO resta il deliverable principale del progetto per motivi di interpretabilità, non perché sia più accurato.

5 I cinque driver sostanziali, spiegati

Effetti standardizzati ($\beta \cdot SD$): la variazione di IFC per un aumento di una deviazione standard del predittore, a parità del resto del modello.

Rango	Variabile	Direzione	$\beta \cdot SD$
1	Massa contribuenti a reddito medio	meno fragile	-1.03
2	Densità totale dei contribuenti	meno fragile	-0.78
3	Massa di reddito dichiarato basso	più fragile	+0.57
4	Quota di reddito da pensione	più fragile	+0.56
5	Densità di piccole imprese di costruzioni	meno fragile	-0.53

Lettura: la fragilità è un equilibrio tra *dinamismo economico* (una classe media ampia e presente; una base ampia di contribuenti; un tessuto di piccole imprese di costruzioni) e *disagio economico* (concentrazione di contribuenti a reddito basso; forte dipendenza da reddito pensionistico piuttosto che da lavoro). Nessuno dei primi cinque driver è una variabile demografica o ambientale — il segnale più forte è inequivocabilmente fiscale/economico.

6 Cosa è stato volutamente escluso dal poster, e perché

- **PCA descrittiva su GRINS e clustering k-means sulle 12 sub-componenti IFC** (contributo di un compagno): sono analisi esplorative/di contesto che confermano che la fragilità è strutturata geograficamente *prima* che venga stimato alcun modello (es. un confronto con la tassonomia di urbanizzazione GRINS, indipendente, mostra l'Italia Interna concentrata nei decili 9-10, l'Italia Metropolitana nei decili 1-2). Motivano gli effetti casuali geografici ma non fanno parte della pipeline predittiva, quindi vivono nell'introduzione/contesto, non nei risultati principali.
- **QQ plot di normalità dei residui e profilo Box-Cox**: diagnostiche reali, riportate per intero nel report di estensione parsimoniosa, ma troppo tecniche da leggere alla distanza di un poster nei pochi secondi che un visitatore dedica a ogni pannello.
- **La tabella completa dei coefficienti a 191 covariate e il log completo dell'iterazione VIF**: disponibili in appendice al report del benchmark; elencarli sul poster non aggiungerebbe informazione che un visitatore potrebbe assorbire sul momento.

7 La conclusione da portare a casa, in tre punti

1. **GRINS predice bene l'IFC**: $R^2 \approx 0.82$ out-of-sample con solo 25 covariate interpretabili più una gerarchia geografica — entro un punto percentuale da un benchmark a 191 covariate e da un modello PLS a 75 componenti.
2. **La narrazione è socio-economica, non demografica o ambientale**: massa di classe media, densità di contribuenti e tessuto di piccole imprese riducono la fragilità; concentrazione di reddito basso e dipendenza da pensione la aumentano.

3. **La geografia conta oltre quanto colgono gli indicatori:** una correlazione intra-classe del 36% più un Moran's $I = 0.234$ persistente e confermato localmente, dopo aver controllato sia per le covariate sia per la geografia amministrativa, mostrano che i modelli spaziali espliciti (SAR/CAR) sono il passo successivo naturale, attualmente non completato.

8 Domande anticipate e risposte preparate

D: Perché LASSO e non Ridge o una selezione stepwise semplice?

LASSO esegue selezione di variabili (azzerando esattamente alcuni coefficienti), cosa che Ridge non fa; questo è essenziale perché l'obiettivo è un modello interpretabile e sparso, non solo a basso errore. Un controllo con Elastic Net su $\alpha \in \{0.1, 0.25, 0.5, 0.75, 1.0\}$ ha mostrato che l'errore di CV varia meno dell'1% su tutto il range, confermando che la scelta di $\alpha = 1$ (LASSO puro) non è arbitraria né fragile.

D: Qual è la differenza tra “feature” e “covariata” nelle slide?

Una feature è una variabile candidata creata durante l'ingegnerizzazione (326 in totale), prima di qualsiasi selezione. Una covariata è una feature che è effettivamente entrata in un modello di regressione stimato (191 dopo LASSO, 25 dopo il raffinamento parsimonioso). Le due parole seguono due fasi diverse della stessa pipeline, non due oggetti diversi.

D: Perché la cross-validation è fatta per comune e non per riga?

Ogni comune appare due volte (2019 e 2021). Dividere per riga permetterebbe a un anno di un comune di allenare il modello mentre l'altro anno dello *stesso* comune lo testa, facendo trapelare informazione e gonfiando l' R^2 in modo otticamente favorevole. Dividere comuni interi nei fold elimina del tutto questa fuga di informazione.

D: Perché escludere la superficie totale?

Su feedback diretto del prof: una volta che ogni altra covariata è espressa come densità o tasso per-capite, la superficie è un descrittore di scala statico, non un driver di fragilità in questa specifica formulazione — mantenerla avrebbe reintrodotta esattamente il tipo di covariata meccanica e non sostanziale che il modello parsimonioso è pensato per evitare.

D: Perché la PCR sui 12 indicatori IFC ufficiali raggiunge solo $R^2 = 0.987$ e non 1.0, se sono letteralmente le componenti dell'indice stesso?

Perché la PCR (e la PCA) possono recuperare solo combinazioni *lineari* delle variabili di input. Il residuo dell'1.3% indica che la costruzione ufficiale dell'IFC include uno step non lineare — molto plausibilmente una trasformazione a rango percentile applicata a un certo punto — che una proiezione lineare non può riprodurre del tutto. Questo è stato confermato dopo aver corretto un problema reale di qualità dei dati (righe comune-anno duplicate nel foglio ufficiale, che gonfiavano silenziosamente l'errore apparente all'1.8% prima della deduplicazione).

D: Perché PLS batte PCR così costantemente?

PCR sceglie le componenti per massimizzare la varianza dentro X da sola; PLS sceglie le componenti per massimizzare la covarianza tra X e Y . Quando le direzioni di massima varianza e massima rilevanza predittiva non coincidono — cosa che il salto osservato a bassissimi numeri di componenti nella curva di trade-off della PCR suggerisce essere il caso qui — PLS ha un vantaggio strutturale che cresce con il disallineamento dimensionale.

D: Se PLS pareggia l'accuratezza di LASSO, perché LASSO resta il vostro deliverable principale?

L'accuratezza non è l'unico criterio che conta per il progetto. Una componente PLS è una combinazione lineare di un numero arbitrario di variabili originali senza un significato individualmente interpretabile; un coefficiente LASSO è attaccato a una variabile nominata, con segno, su cui un decisore pubblico può agire. Il brief del progetto chiede esplicitamente un benchmark *interpretabile*, quindi LASSO è preferito a parità di accuratezza.

D: Perché il modello spaziale esplicito (SAR/CAR) non è stato completato?

È stato tentato seriamente; il modello non è convergiuto in un tempo di calcolo praticabile su

un dataset di questa dimensione (15.782 osservazioni panel con una matrice di pesi spaziali a livello comunale densa). Piuttosto che riportare coefficienti non attendibili da una stima non convergente, il tentativo è documentato come un limite onesto e un passo successivo chiaramente identificato, supportato dall'evidenza del Moran's I /LISA che un tale modello è di fatto giustificato.

D: Cosa significa davvero la correlazione intra-classe del 36%?

Dopo che le 25 covariate a effetto fisso hanno fatto il loro lavoro, la varianza *residua* dell'IFC si divide circa al 36% a “in quale regione/provincia si trova un comune” (un'etichetta, non una covariata misurata) e al 64% a tutto il resto (variazione comunale idiosincratICA, rumore di misura, e la componente spazialmente correlata confermata in seguito da Moran's I /LISA).

D: Quanto dovremmo fidarci dei primi 5 driver — potrebbero essere un artefatto della multicollinearità?

La selezione parsimoniosa impone $VIF < 10$ per ogni covariata mantenuta (il VIF massimo osservato è 6.4), specificamente per escludere questo dubbio; tutti i cinque driver principali restano significativi a $p < 10^{-6}$ anche dopo che lo step di sostituzione iterativa ha rimosso i concorrenti collineari.